

5.12.2023

Sygnały i Obrazy Cyfrowe

Sprawozdanie 3 – Demozaikowanie i zastosowania konwolucji

Mateusz Marko, grupa nr 1, TN wt 17:05
Nr 273168, ISA

1. Cel ćwiczenia #1- Demozaikowanie

Celem ćwiczenia jest zademonstrowanie procesu demozaikowania, czyli odtwarzania obrazów kolorowych z mozaik, oraz ocena ich jakości w zależności od zastosowanej metody. Zadanie można wykonać korzystając z różnych metod np. konwolucją 2D czy interpolacją. Przy całym procesie istotne jest też wybranie odpowiedniego filtru, gdyż stosując odmienne filtry kolorów (maski) otrzymamy odmienne zdemozaikowane obrazy końcowe, co końcowo przełoży się na jakość którą będziemy musieli porównać i subiektywnie ocenić efektywność procesów. Do konkretnego rodzaju mozaiki powinniśmy zastosować odpowiedni dla niej filter.

2. Wstęp teoretyczny

• Demozaikowanie

W fotografii cyfrowej, każdy piksel przechowuje informacje o jednym kolorze (czerwonym, zielonym lub niebieskim), a układ tych kolorów nazywany jest mozaiką. Mozaika to wzór rozmieszczenia kolorów w pikselach, różny dla różnych producentów aparatów. To kluczowy element wpływający na sposób, w jaki zbierane są informacje o natężeniu światła. Konieczne jest zatem przekształcenie tych danych w pełny obraz kolorowy. Demozaikowanie jest więc procesem „odczytu”, w którym rekonstruuje się obraz RGB na podstawie pomiarów natężenia światła i informacji z czujników koloru CFA (Color Filter Array). Celem demozaikowania jest więc uzyskanie pełnego obrazu oryginalnego, który wiernie odzwierciedla barwy i detale sceny. Proces ten ma wpływ na ostateczną jakość obrazu i jest niezbędny w fotografii cyfrowej, aby uzyskać realistyczne i pełne kolorów zdjęcia. Proces ten był niezbędny, jako że softwarowo było to znacznie prościej zrealizować oraz ze znacznie mniejszym nakładem finansowym niż hardwarowo.

• Filtry kolorów

Masek używa się do zbierania informacji o kolorach na podstawie natężenia światła. Każda maska ma unikalną macierz rozmieszczenia kolorów. Maski, takie jak Maska Bayera i Maska Fuji, definiują rozmieszczenie kolorów na matrycy sensora. Ich zastosowanie wpływa na sposób, w jaki dane są gromadzone i jakie informacje są dostępne dla każdego piksela. Metody więc muszą uwzględniać strukturę masek kolorów, rozmieszczenie pikseli oraz specyficzne cechy danej maski.

a) Maska Bayera

Maska Bayera to popularna technika filtracji kolorów stosowana w matrycach kolorów cyfrowych sensorów obrazu. Przedstawia się jako dwuwymiarowa macierz o kwadratowym kształcie, gdzie poszczególne elementy macierzy reprezentują różne kolory (czerwony, zielony, niebieski). Piksele są rozmieszczone w taki sposób, że sąsiednie piksele reprezentują różne kolory, co zapewnia równomierną reprezentację kolorów na całej matrycy. Maska Bayera jest szeroko stosowana w procesie demozaikowania, który ma na celu odtworzenie pełnego obrazu kolorowego z danych zebranych przez sensor. Istnieją różne warianty masek Bayera, takie jak 2x2, 4x4 lub 8x8, które wpływają na dokładność rekonstrukcji kolorów. Maska ta jest uniwersalnie używana w aparatach cyfrowych, chociaż różni producenci mogą stosować różne warianty, co wpływa na ostateczną jakość obrazu i proces demozaikowania.

$$\text{maska Bayera} - B = \begin{bmatrix} G & R \\ B & G \end{bmatrix}$$

, gdzie Wartości '*R*', '*G*' i '*B*' oznaczają oczywiście obecność pomiaru natężenia światła kolorów czerwonego, zielonego i niebieskiego.

G	R	G	R	G	R
B	G	B	G	B	G
G	R	G	R	G	R
B	G	B	G	B	G
G	R	G	R	G	R
B	G	B	G	B	G


Rysunek 1 Przykładowa maska Bayera

b) Maska Fuji

Maska Fuji to kolejna popularna technika filtrowania kolorów także używana w matrycach kolorów cyfrowych sensorów obrazu, szczególnie w aparatach firmy Fuji X-Trans. Jest to również dwuwymiarowa macierz, ale o bardziej złożonej strukturze niż Maska Bayera. Maska Fuji ma rozmiar 6x6 i charakteryzuje się bardziej skomplikowanym wzorem rozmieszczenia kolorów niż Maska Bayera. Podobnie jak Maska Bayera, Maska Fuji jest używana w procesie demozaikowania do uzyskania pełnego obrazu kolorowego. Jej zastosowanie wymaga specjalnej uwagi podczas implementacji algorytmów demozaikowania, ze względu na bardziej złożoną strukturę rozmieszczenia kolorów w matrycy. W praktyce, różnice między Maską Bayera a Maską Fuji wpływają na ostateczny efekt w rekonstrukcji kolorów i jakość obrazu.

$$maska\ Fuji - F = \begin{bmatrix} G & B & R & G & B & R \\ R & G & G & B & G & G \\ B & G & G & R & G & G \\ G & B & R & G & B & R \\ R & G & G & B & G & G \\ B & G & G & R & G & G \end{bmatrix}$$

, gdzie Wartości 'R', 'G' i 'B' oznaczają oczywiście obecność pomiaru natężenia światła kolorów czerwonego, zielonego i niebieskiego.



Rysunek 2 przykładowa maska Fujifilm X-Trans

- Metody Demozaikowania

- a) Interpolacja

Demozaikowanie metodą interpolacji to proces, w którym dane zebrane przez cyfrowy sensor obrazu są przekształcane w pełny obraz kolorowy poprzez estymację brakujących informacji między pikselami, w odpowiednich kolumnach i wierszach z uwzględnieniem rozmieszczenia kolorów w mozaice korzystając z metod interpolacji, takich jak interpolacja kolorów czerwonego, zielonego i niebieskiego w odpowiednich kierunkach, co umożliwia uzyskanie wiernego obrazu o pełnej gamie kolorów.

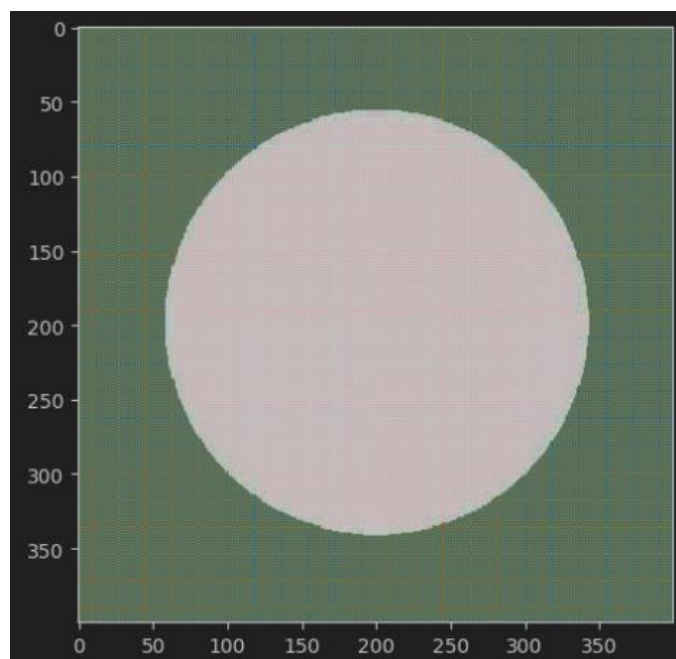
- b) Konwolucja 2D

Demozaikowanie metodą konwolucji 2D przekształca zebrane przez sensor cyfrowy dane w finalny kolorowy obraz dzięki użyciu odpowiednio dobranych masek konwolucji, które będą "przepisywały" lub uśredniały wartości kolorów z sąsiednich pikseli. Przy korzystaniu z konwolucji musimy pamiętać o ustawieniu odpowiedniego kroku. Wzmocnienie powinno być dostosowane do rozmieszczenia kolorów na matrycy i być proporcjonalne do ilości pikseli w danym kolorze. Pozwoli nam to uzyskać finalny obraz z pełną gamą kolorów. Jądro konwolucji dla danego piksela ma wzmocnienie równe sumie jego wartości. Należy pamiętać że niektóre biblioteki numeryczne dodają sztuczne piksele do obrazu (ang. padding), tak by pozostał niezmienny przez konwolucję. Może to jednak powodować błędy przy brzegach obrazu. Aby temu zapobiec należy wykonywać wypełnianie pikselami o wartości zero.

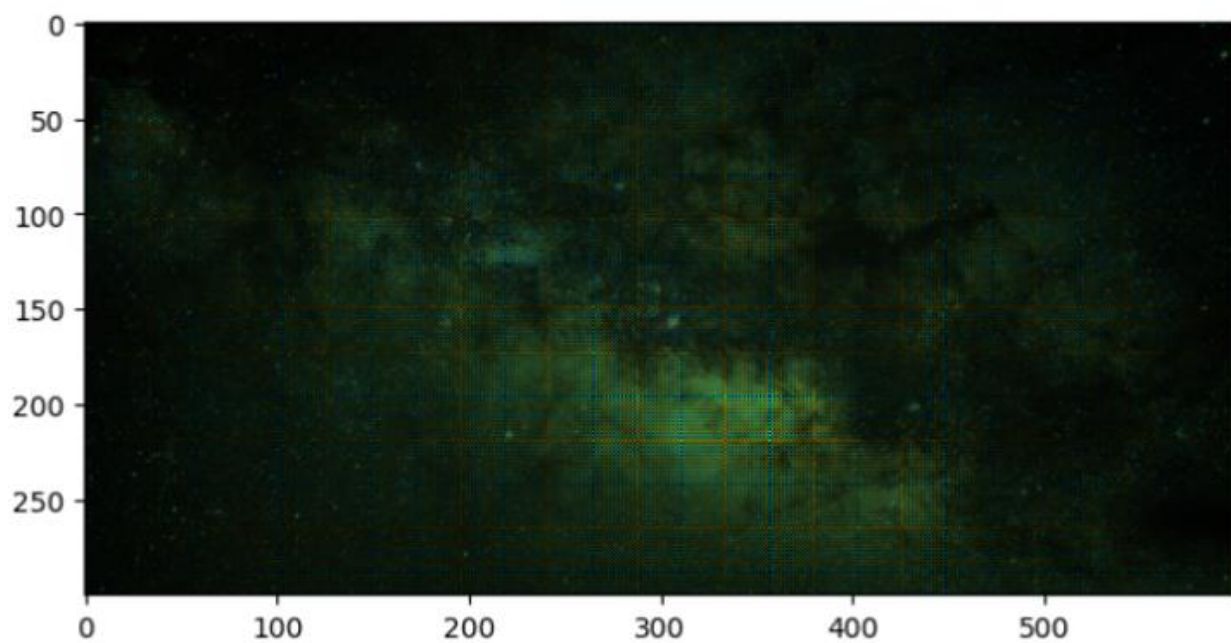
3. Przebieg ćwiczenia

W zadaniu trzeba było wykonać demozaikowanie wybranych otrzymanych wcześniej obrazów korzystając z dwóch wyżej podanych metod - konwolucją 2D oraz interpolacją dla filtru Bayera. I na tak otrzymanych już obrazach należało porównać subiektywnie ich jakość i jakie mogą zachodzić między nimi różnice zachodzące przez odmiennosć stosowanych metod do demozaikowania. Można było także dodatkowo wykonać demozaikowanie obrazów już dowolną metodą dla nieco bardziej złożonego filtru Fuji.

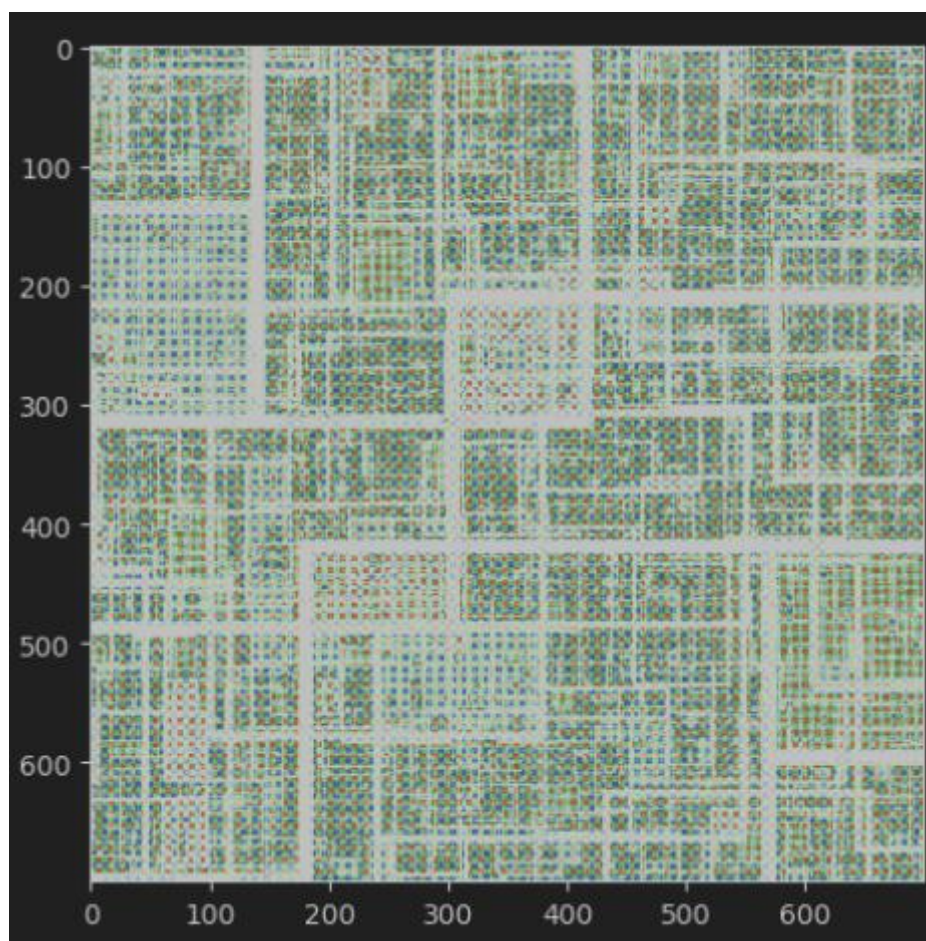
- a) Obrazy przed zdemozaikowaniem



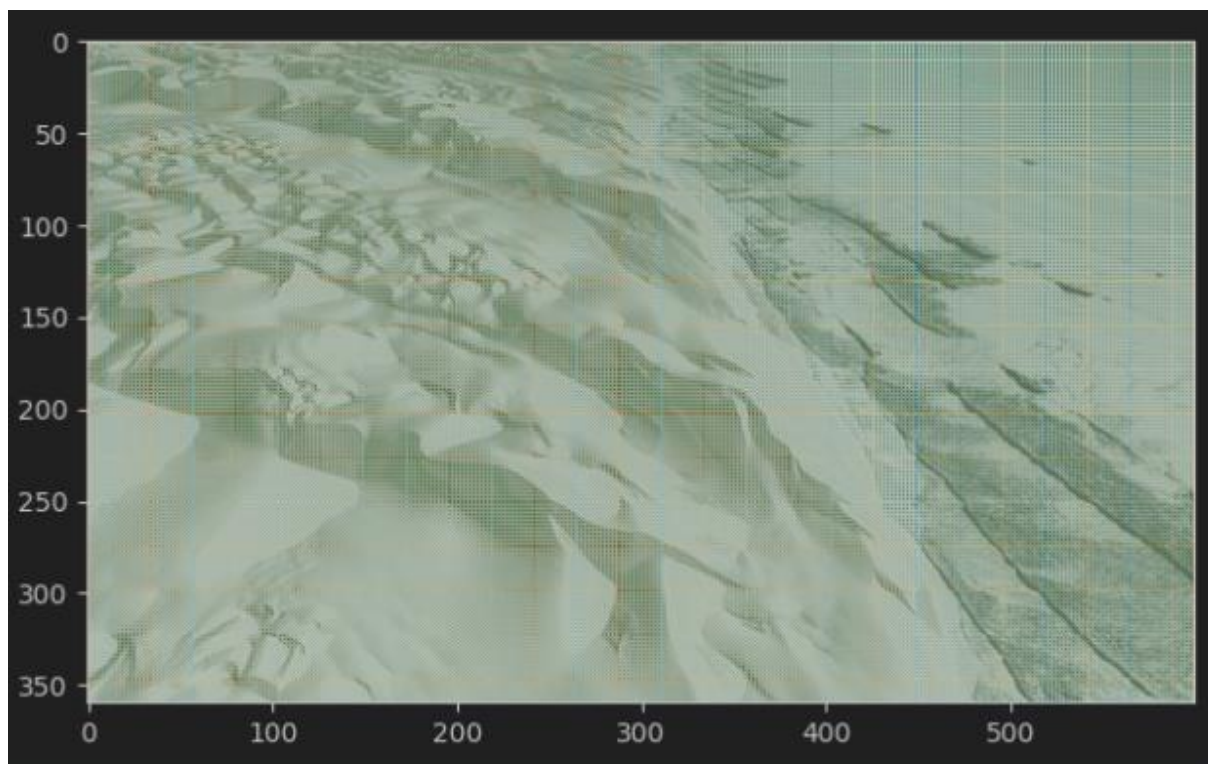
Rysunek 3 Obraz zamozaikowany 1




Rysunek 4 Obraz zamozaikowany 2



Rysunek 5 Obraz zamozaikowany 3

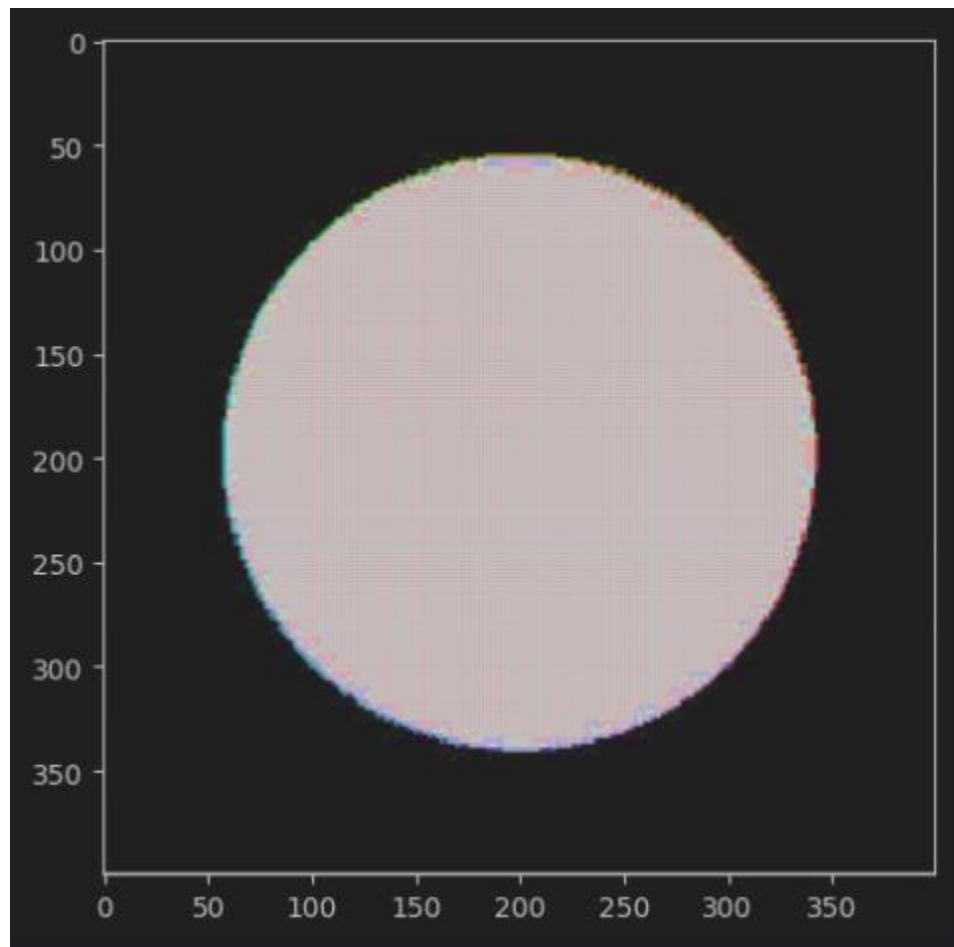


Rysunek 6 Obraz zamozaikowany 4




Rysunek 7 Obraz zamozaikowany 5


b) Demozaikowanie przy użyciu interpolacji




Rysunek 8 Obraz 1 zdemozaikowany przy użyciu interpolacji



Rysunek 9 Obraz 2 zdemozaikowany przy użyciu interpolacji



Rysunek 10 Obraz 3 zdemosaikowany przy użyciu interpolacji




Rysunek 11 Obraz 4 zdemosaikowany przy użyciu interpolacji




Rysunek 12 Obraz 5 zdemozaikowany przy użyciu interpolacji

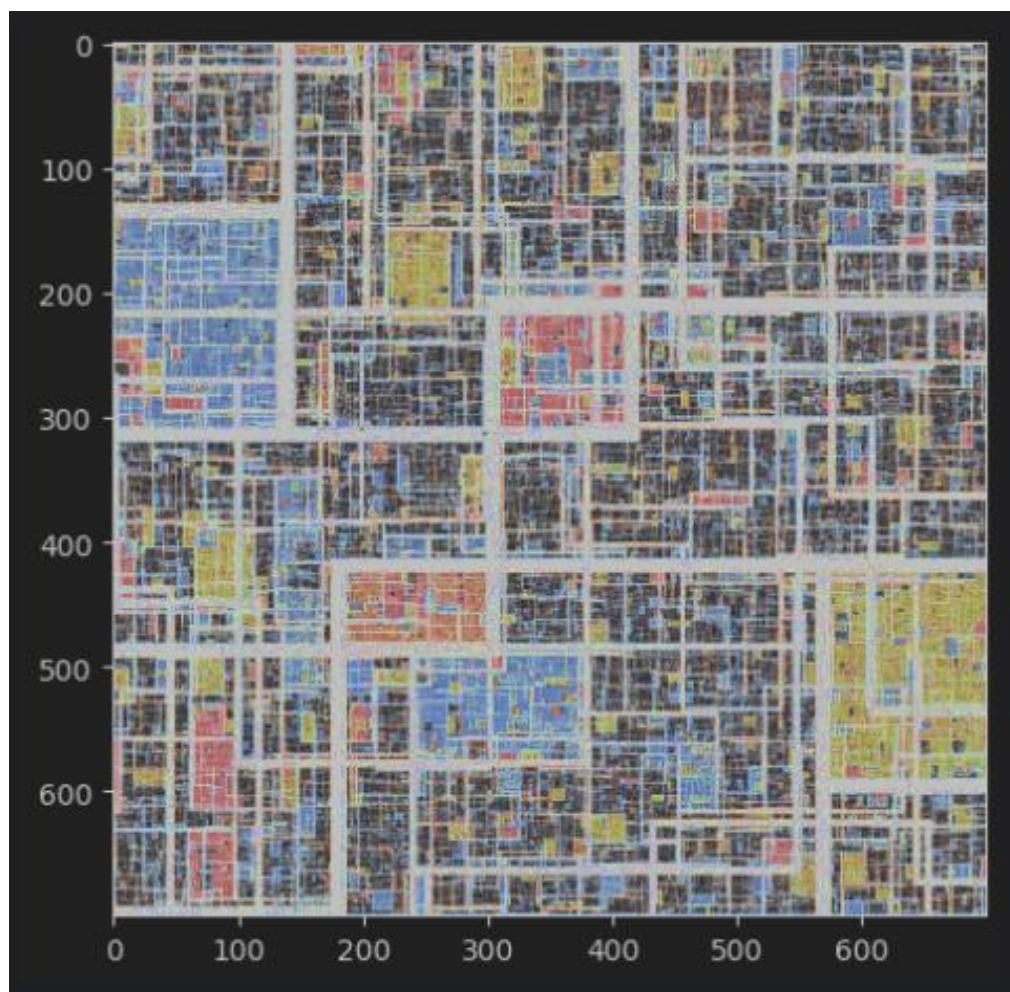
c) Demozaikowanie przy użyciu konwolucji 2D




Rysunek 13 Obraz 1 zdemozaikowany przy użyciu konwolucji 2D



Rysunek 14 Obraz 2 zdemozaikowany przy użyciu konwolucji 2D



Rysunek 15 Obraz 3 zdemozaikowany przy użyciu konwolucji 2D



Rysunek 16 Obraz 4 zdemozaikowany przy użyciu konwolucji 2D



Rysunek 17 Obraz 5 zdemozaikowany przy użyciu konwolucji 2D


- Filtr Fuji

Tutaj mamy obrazy praktycznie nie zamozaikowane (nie jestem pewien czy faktycznie tak powinno być) zatem po procesie demozaikowania filtrem fuji otrzymujemy wynik rzeczywiście zdaje się lepszy jakościowo niż wcześniejsze metody stosujące maskę bayera. Sam obraz jednak wychodzi niestety nieco zbyt czerwony.


- Obrazy wejściowe



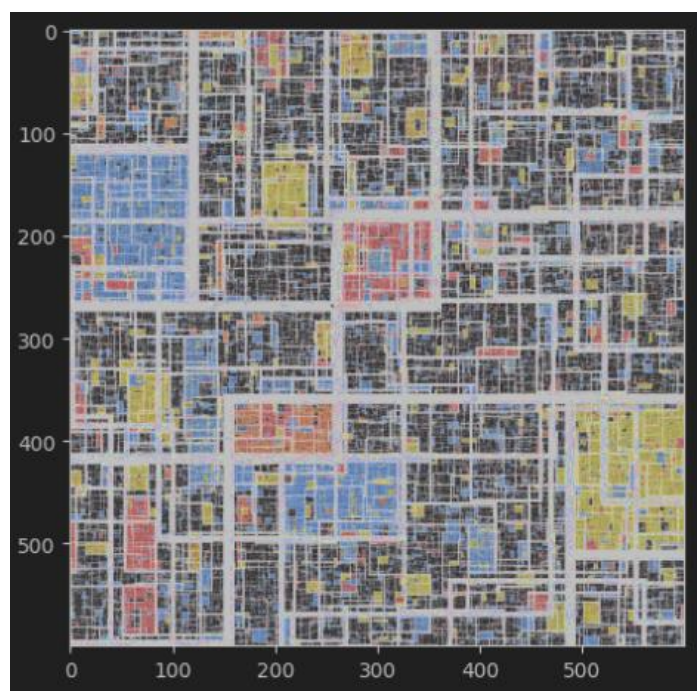
Rysunek 18 Obraz wejściowy 1




Rysunek 19 Obraz wejściowy 2



Rysunek 20 Obraz wejściowy 3



Rysunek 22 Obraz wejściowy 4




Rysunek 21 Obraz wejściowy 5


- Obrazy sensora po nałożeniu maski Fuji X-Trans



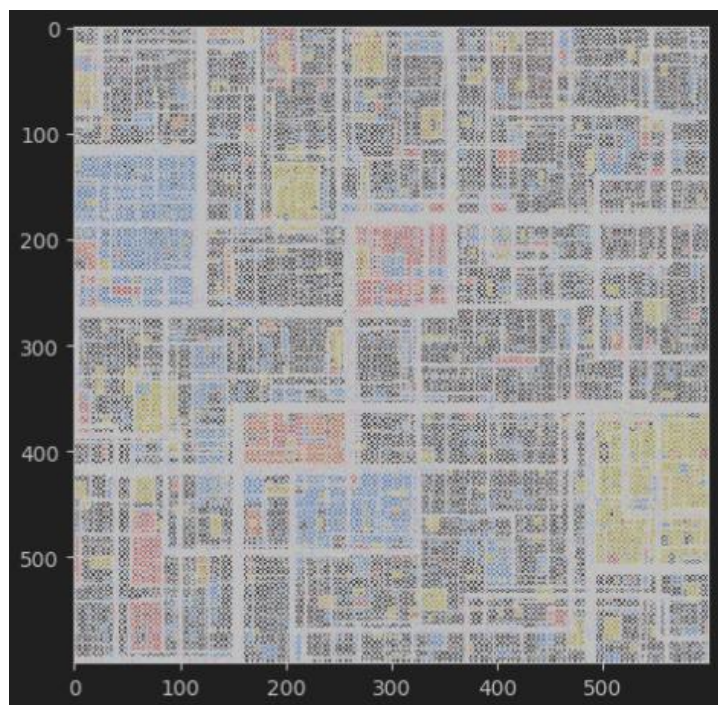
Rysunek 23 Obraz sensora 1 po nałożeniu maski Fuji X-Trans




Rysunek 24 Obraz sensora 2 po nałożeniu maski Fuji X-Trans



Rysunek 25 Obraz sensora 3 po nałożeniu maski Fuji X-Trans



Rysunek 26 Obraz sensora 4 po nałożeniu maski Fuji X-Trans




Rysunek 27 Obraz sensora 5 po nałożeniu maski Fuji X-Trans


- Obrazy wyjściowe po zdemozaikowaniu



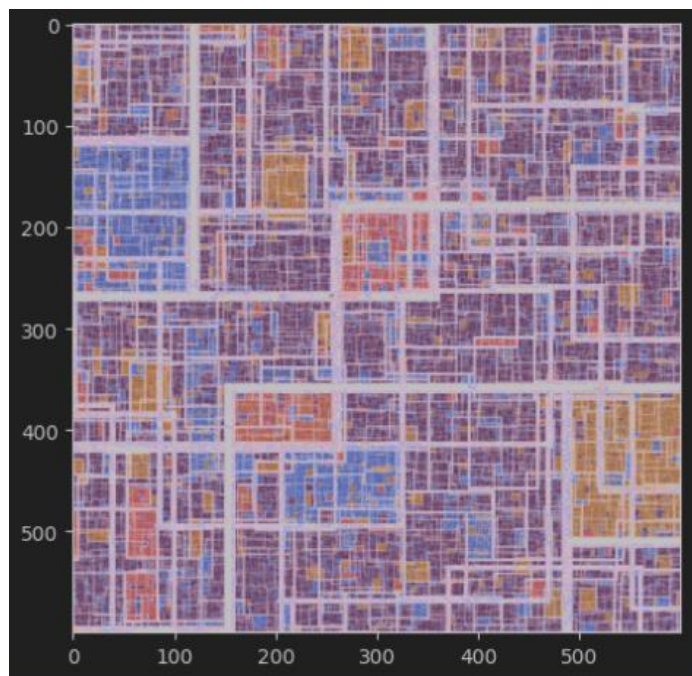
Rysunek 28 Obraz zdemozaikowany 1



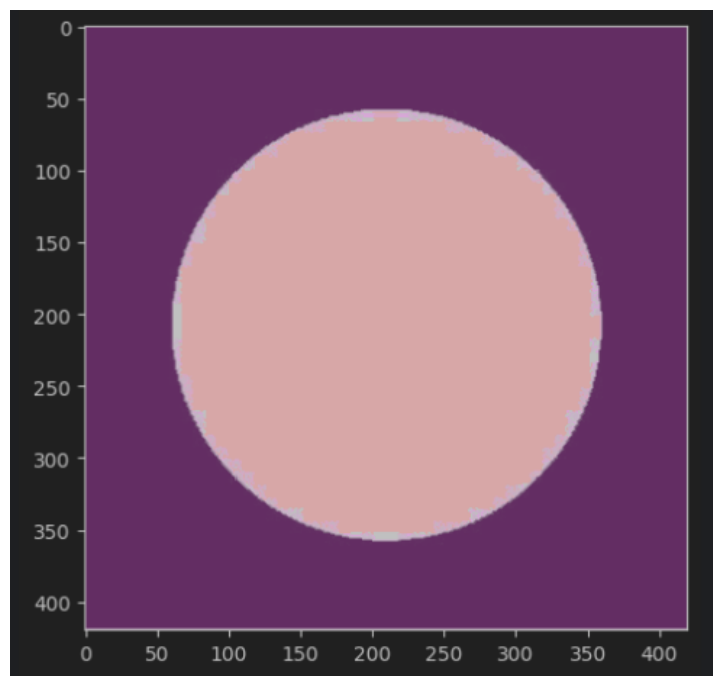
Rysunek 29 Obraz zdemozaikowany 2



Rysunek 30 Obraz zdemozaikowany 3



Rysunek 32 Obraz zdemozaikowany 4




Rysunek 31 Obraz zdemozaikowany 5


- Z początku zaimplementowane przeze mnie demozaikowania nie działały poprawnie, jak się później okazało ze względu na fakt, że wysłane obrazy mozaik ulegały kompresji i drobnej zmianie w końcowym odczycie pliku dlatego lepiej odczytywać je w formie BIN. By sprawdzić więc poprawność algorytmów dodatkowo zaimplementowałem przykładowe mozaikowanie by potem demozaikować dowolnie wybrany obraz.



Rysunek 34 Obraz wejściowy do demozaikowania



Rysunek 33 Obraz wejściowy zamozaikowany



Rysunek 35 Obraz wyjściowy zdemozaikowany

4. Wnioski

- Po otrzymaniu obrazków ciężko jednoznacznie ocenić, która z metod wygeneruje nam lepszy obraz lecz subiektywnie mogę stwierdzić, że obraz po konwolucji wydaje się nieco lepszy i wyraźniejszy po porównaniu ze sobą ostatecznych obrazów. Może dawać ciut lepsze rezultaty ze względu na jej zdolność do uwzględniania lokalnych struktur i adaptacji do różnych tekstur w obrazie. Interpolacja może wprowadzać niepasujące artefakty, zwłaszcza w obszarach o dużym kontraście kolorów. Możemy więc stwierdzić że obrazkowi po konwolucji jednak bliżej do oryginału.
- Subiektywnie widzę także różnice na konturach elementów i na granicach przeciwnie zestawionych ze sobą kolorów. Możemy zobaczyć to chociażby na obrazku z kołem gdzie obie metody miały problem z granicami kolorów i konwolucja nawet dodała dodatkowo czerwony kolor a same krawędzie były nieostre. Cały obraz nie oddaje oryginalnej jakości lecz został jakby lekko zapikselowany. Więc choć może odmienności wydają się niewielkie to wciąż jednak nielicznie wizualnie występują w zależności od dobranej metody.
- Poprzez to, iż nasze oko jest wyczulone najbardziej na kolor zielony, najwięcej informacji jest zachowanej właśnie o nim. Dlatego w macierzy Bayera 2x2, kolor zielony powtarza się zawsze 2 razy, a pozostałe raz. Natomiast w macierzy X-Trans 6x6, kolor zielony możemy zauważyć 20 krotnie, pozostałe po 8 razy.
- Im więcej pikseli, tym na ogół obraz powinien wyglądać lepiej gdyż jest większa ilość punktów z których można lokalnie zaczerpnąć informacje i otrzymamy dokładniejszą reprezentację oryginału dla każdej z metod. Z kolei z mniejszą liczbą punktów dla takiej interpolacji tracimy na dokładności. Interpolacja może być bardziej przybliżona, a istotne drobnostki mogą zostać po prostu pominięte jest jednak prosta do zrozumienia i zaimplementowania a także nieco szybsza i efektywna obliczeniowo. Mniejsze obrazy będą zatem gorzej demozaikowane i przedstawią znacznie mniej szczegółów po całym procesie przez brak potrzebnych danych.
- Metoda konwolucji z kolei uwzględnia lokalne struktury obrazu dzięki wykorzystaniu konkretnych jąder konwolucyjnych. Może więc dostosować się do różnych tekstur i wzorców w obrazie przy odpowiednim doborze parametrów. Niestety metoda ta jest ciut bardziej złożona obliczeniowo niż prosta interpolacja oraz wymaga odpowiedniego dostrojenia parametrów.
- Maski Fuji X-Trans pomimo tego że dała obrazy w nieco innym kolorze, jakościowo wydaje się być znacznie lepsza i każdy obraz nią zdemozaikowany zdaje się być bardzo zbliżony do oryginału. Krawędzie są ostre cały obraz gładki i nie posiada zbyt wielu widocznych pikseli. Od razu jesteśmy więc w stanie wywnioskować że jej złożoność oraz jej większy rozmiar od maski Bayera ma przełożenie na to co otrzymamy na końcu. Pomimo tego, że wciąż będą występować jakieś zniekształcenia, będzie po prostu dokładniejsza niż prymitywna maska 2x2.
- Istotne jest także dostosowanie obrazu na którym będziemy działać do samej operacji. Jak można było tego doświadczyć jedynie drobna zmiana w obrazach wejściowych bądź złe jego przygotowanie może skutkować negatywnym rezultatem końcowym.
- Bardzo wiele więc zależy od rodzaju dobrego obrazu, kolorów jakie posiada i jego wielkości. W zależności od tego jakie parametry będzie miał obraz jedna metoda może zadziałać efektywniej niż druga i lepiej urzeczywistniać oryginał. Należy pamiętać że każda z nich charakteryzuje się nieco innymi cechami i kluczowy jest zarówno dobór odpowiedniej maski jak i metody demozaikowania.

5. Cel ćwiczenia #2- zastosowania konwolucji

Celem tego ćwiczenia jest zapoznanie się i przedstawienie wielorakich możliwości zastosowania konwolucji w przetwarzaniu obrazów. Zastosowanie różnych jąder konwolucji umożliwia dostosowanie przetwarzania obrazów do konkretnych celów, takich jak poprawa wyrazistości, redukcja szumów, czy wyostrenie kluczowych elementów na obrazie a także blur. W zadaniu należało zaimplementować konwolucję dyskretną do wykrywania krawędzi, rozmywania, wyostrania oraz usuwania szumu.

6. Wstęp teoretyczny

- Zastosowania konwolucji

- a) Wykrywanie krawędzi obrazu

W przetwarzaniu obrazów do wykrywania krawędzi stosuje się gradienty jasności, przy czym duże zmiany jasności sugerują obecność krawędzi na obrazie. Do tego celu można użyć operatorów Sobela dla osi X (S_x) oraz Y (S_y) lub operatora Laplace'a (L), które są przybliżeniem pochodnej obrazu w osi X lub Y, bądź gradientu, i które są zoptymalizowane do wykrywania zmian gradientu w obrazie. Operatory Sobela są zoptymalizowane do wykrywania zmian gradientu, co skutkuje wyostreniem krawędzi i ułatwia analizę struktury obiektów na obrazie. Warto zauważyć, że operatory te są czułe na kierunek zmiany jasności, co może wpłynąć na rezultaty, a także mogą zmieniać zakres obrazu, co może skutkować wartościami pikseli mniejszymi niż 0 lub większymi niż 1.

$$S_x = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix}, \quad S_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}, \quad L = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

, gdzie S_x to przykładowy operator dla osi X, S_y to przykładowy operator dla osi Y, L to przykładowy operator Laplace'a

- b) Rozmywanie obrazu

W procesie rozmywania obrazu wykorzystuje się jądra konwolucji o równych wagach, np. jądro Gaussa (G), które uśrednia wartość pikseli w danym obszarze. To rozmycie zmniejsza ostrość i kontrast obrazu, co może być korzystne do eliminacji drobnych szczegółów, redukcji szumów oraz uzyskania efektu estetycznego. W przypadku rozmycia obrazu, zarówno przy użyciu jądra Gaussa, jak i jądra uśredniającego, konieczne jest zastosowanie konwolucji z odpowiednim krokiem, aby uzyskać pożądany efekt.

$$G = \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 1 & 4 & 1 \\ 1 & 2 & 1 \end{bmatrix}$$

, gdzie G to przykładowe jądro Gaussowskie

- c) Wyostrenie obrazu

Wyostrenie obrazu (W) jest operacją zestawioną z rozmyciem i detekcją krawędzi. Rozmywanie usuwa wysokie częstotliwości z obrazu, a detekcja krawędzi usuwa niskie częstotliwości. Wyostrenie polega na podbiciu wysokich częstotliwości, przy użyciu jądra do wyostrania, co wzmacnia detale bez utraty niskich częstotliwości. Czasem do wyostrania obrazu można użyć też jąder, takich jak jądro Laplace'a, które zwiększają kontrast między sąsiednimi pikselami, podkreślając obszary o szybkich zmianach intensywności. Ten proces sprawia, że krawędzie są wyraźnie podkreślone, co może poprawić ogólną jakość i ostrość obrazu.

$$W = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

, gdzie W to przykładowe jądro do wyostrozania

d) Usuwanie szumu z obrazu

Wykorzystuje się jądra konwolucji, takie jak jądro medianowe, które zastępuje wartość piksela medianą w danym obszarze. Eliminuje pojedyncze zakłócenia i szumy, pozostawiając istotne struktury obrazu. Jest skuteczne w przypadku szumów impulsowych lub losowych.


7. Przebieg ćwiczenia

Zadanie polegało na zaimplementowaniu algorytmu, który umożliwi kolejno wykrywanie krawędzi obrazu, rozmywanie go, wyostrozanie oraz pozwoli nam usunąć szum z obrazu, wszystko oczywiście przy zastosowaniu konwolucji dyskretniej, każde za pomocą jednego filtru na przykład Sobela, Laplaca lub Gaussa. Można było także dodatkowo zaimplementować dodatkowe filtry krawędzi, takie jak operator Sobela-Feldmana, operator Scharra lub Operator Prewitta. A także zaimplementować jeszcze inne filtry wyostrzające, można też utworzyć detektor Sobela czy rozmycie Gaussowskie z większym rozmiarem jądra.

a) Wykrywanie krawędzi obrazu




Rysunek 36 Obraz oryginalny




Rysunek 37 Obraz po zastosowaniu operatora Laplace'a na wykrywanie krawędzi


- Zestawione ze sobą dodatkowe filtry krawędzi, operator Sobela-Feldmana, operator Scharra i Prewitta



Rysunek 38 Całościowe zestawienie filtru krawędzi dla operatora Sobela-Feldmana



Rysunek 39 Całościowe zestawienie filtru krawędzi dla operatora Scharra



Rysunek 40 Całościowe zestawienie filtru krawędzi dla operatora Prewitta

b) Rozmywanie obrazu



Rysunek 41 Obraz oryginalny



Rysunek 42 Obraz po rozmyciu jądrem Gaussa



Rysunek 43 Obraz po rozmyciu jądrem uśredniającym

- W programie zaimplementowałem również rozmycie Gaussowskie z większym dowolnym rozmiarem jądra.



Rysunek 44 Przykładowy obraz z jądrem Gaussowskim 5 na 5 i rozmyciem



Rysunek 45 Przykładowy obraz z większym jądrem Gaussowskim 7 na 7 i rozmyciem

c) Wyostczenie obrazu



Rysunek 46 Obraz oryginalny



Rysunek 47 Obraz po wyostczeniu

d) Usuwanie szumu z obrazu



Rysunek 48 Obraz oryginalny



Rysunek 49 Obraz z usuniętym szumem

8. Wnioski

- Filtry krawędziowe, takie jak Sobel czy Laplace, są skuteczne w wykrywaniu zmian gradientu, co prowadzi do wyostrenia krawędzi w obrazie. Jądro Laplace'a poza tym również jest efektywne w podkreślaniu obszarów o szybkich zmianach intensywności, co poprawia ogólną jakość obrazu i wyostrza detale. Zastosowanie owych operatorów, poza tym że jest w stanie wykryć krawędzie może też efektywnie zwiększać kontrast między sąsiednimi pikselami, co prowadzi do wyraźniejszych krawędzi i zdefiniowanego obrazu. Filtr wyostrający (np. nasze jądro W) pozwala podkreślić wysokie częstotliwości, co przyczynia się do wzmocnienia detali bez utraty niskich częstotliwości.
- Filtr Sobela jest dobry w wykrywaniu krawędzi w pionie i poziomie. Skupia się głównie na wykrywaniu zmian intensywności w obrazie. Jego dwa jądra (jeden dla poziomych zmian intensywności, drugi dla pionowych) pozwalają na skoncentrowane wykrywanie krawędzi o różnych orientacjach.
- Filtr Laplace'a zaś jest stosowany do detekcji krawędzi poprzez podbicie różnic intensywności wokół punktu centralnego. Jego użycie jest bardziej ogólne niż Sobela, ale może być bardziej wrażliwe na szum w obrazie co czasem może przełożyć się na lepszą jakość.
- Stosowanie konwolucji z jądrem o równych wagach, jak jądro Gaussa, prowadzi do efektywnego rozmycia obrazu poprzez średnią wartości pikseli w danym obszarze. Rozmycie Gaussowskie z jądrem ważonym rozkładem normalnym może być też używane do uzyskania efektu estetycznego poprzez redukcję ostrości i kontrastu.
- Filtr uśredniający stosuje proste uśrednianie wartości pikseli w określonym obszarze. Każdy piksel w wynikowym obrazie jest uśredniany z sąsiednimi pikselami. Ma on więc prostą implementację i jest efektywny, ale może wprowadzać pewne niepożądane artefakty, szczególnie w obszarach o dużym kontraście.
- Filtr Gaussowski jest nieco odmienny. Wykorzystuje rozkład Gaussa, co oznacza, że każdy piksel w wynikowym obrazie jest ważony na podstawie funkcji Gaussa w określonym obszarze. Jest bardziej zaawansowany niż filtr uśredniający, ponieważ uwzględnia różnice wagi pikseli w zależności od odległości od piksela centralnego. Daje więc bardziej naturalne i estetyczne wyniki. Jest bardziej efektywny w redukcji szumów i artefaktów wprowadzanych przez filtr uśredniający
- Wybór więc odpowiedniego filtra zależy od konkretnego celu przetwarzania obrazu. Filtr Sobela jest przydatny do detekcji krawędzi i jak już wyżej zazaczyłem robi to w nieco odmienny sposób niż jądro Laplace'a czy Prewitta jednak różnice to subiektywna opinia. Filtry rozmywające, takie jak rozmycie Gaussowskie i uśredniające, mają zastosowanie w redukcji szumów i uzyskiwaniu efektu rozmycia lecz także mają swoje różnice.
- Wyniki te pokazują jak ważny jest wybór odpowiednich jąder konwolucji w zależności od zamierzonego celu przetwarzania obrazu. Dobór ten może znacząco wpłynąć na jakość i wyrazistość końcowego obrazu. Samą konwolucją jesteśmy w stanie rozmazać obraz ale i go wyostrzyć. Wykryć krawędzie ale i usunąć szum. Widzimy zatem jak ważną i wielofunkcyjną rolę odgrywa zastosowanie konwolucji w kontekście przetwarzania obrazu. Należy jednak pamiętać także o odpowiednim dostosowaniu parametrów takich jak padding czy stride (krok).